SECRETARÍA DE EDUCACIÓN PÚBLICA

TECNOLÓGICO NACIONAL DE MÉXICO

INSTITUTO TECNOLÓGICO DE VERACRUZ

ASIGNATURA: INTELIGENCIA ARTIFICIAL

PROYECTO UNIDAD 2: SISTEMA INTELIGENTE PARA EL ANALISIS DE TICKETS DE SOPORTE TECNICO.

CARRERA: INGENIERÍA EN SISTEMAS COMPUTACIONALES

DOCENTE: MANUEL ANTONIO LOPEZ HORTA

HORARIO: LUNES-JUEVES 18-19 HRS

SEMESTRE: AGOSTO/DICIEMBRE 2026.

INTEGRANTES EQUIPO CRUZAZULITOS:

GARCÍA HERNÁNDEZ ROBERTO JOAQUÍN

MORALES VILLARAUS LUIS DANIEL

PARRA HUERTA FRANCISCO ALEJANDRO

XALA HERNÁNDEZ SARELY

Índice

Índice de figuras 4
Introducción 5
ETAPA 1 IDENTIFICACIÓN DE LA PROBLEMÁTICA 6
Análisis del Problema 7
Planteamiento del problema 7
Antecedentes 7
Justificación 8
Objetivo general 8
Objetivos específicos 8
Alcance 9
Funciones del sistema y resultados esperados 9
Limitaciones 10
Usuarios potenciales 10
ETAPA 2 DISEÑO DE LA SOLUCION INTELIGENTE 11
Funcionamiento y componentes del sistema 12
Adquisición y Preparación de Datos 12
Descripción de las variables 12
Fuente de información 14
Cantidad de registros 14
Tipos de datos 14
Tratamiento de valores faltantes 15
Tratamiento de valores atípicos 15
Transformaciones realizadas 16
Justificación del enfoque de IA y técnicas de PNL seleccionadas 17
Modelo de Machine Learning 18
Definición del problema 18
Tipo de aprendizaje 18
Algoritmo seleccionado 18
Características utilizadas 18
Variable objetivo 19

Preparación de datos 19

Índice de figuras

Introducción

En la actualidad, la dependencia tecnológica de las organizaciones ha convertido a las mesas de ayuda (Help Desk) en un pilar fundamental para garantizar la continuidad operativa. Sin embargo, la gestión tradicional de soporte técnico enfrenta un desafío crítico: la saturación y los cuellos de botella generados por la asignación manual de prioridades. Al depender del criterio subjetivo de los usuarios, quienes frecuentemente catalogan cualquier incidente menor como "urgente", los departamentos de Tecnologías de la Información (TI) pierden la capacidad de distinguir rápidamente entre solicitudes rutinarias y verdaderas emergencias de infraestructura.

Para resolver esta problemática, el presente proyecto plantea el diseño de un "Sistema inteligente para el análisis de tickets de soporte técnico". Esta solución tecnológica integra herramientas de Inteligencia Artificial, específicamente algoritmos de aprendizaje automático (Machine Learning) y técnicas de Procesamiento de Lenguaje Natural (PNL), con el propósito de analizar la redacción de los usuarios y automatizar la clasificación de la prioridad de cada incidente de manera objetiva y eficiente.

ETAPA 1
IDENTIFICACIÓN DE LA PROBLEMÁTICA

Análisis del Problema

Planteamiento del problema

Actualmente, las mesas de ayuda enfrentan un severo problema operativo derivado de la clasificación y asignación manual de prioridades en los reportes de soporte técnico. Al ser los propios usuarios quienes determinan de forma empírica la urgencia de sus solicitudes, se genera un sesgo donde la gran mayoría de los incidentes son etiquetados erróneamente como "críticos" o "urgentes".

Esta falta de un criterio objetivo y estandarizado produce cuellos de botella operativos en el departamento de TI, impidiendo diferenciar los incidentes menores (como dudas de software o cambio de consumibles) de las fallas críticas de infraestructura (como caídas de servidores centrales, bloqueos de bases de datos o vulnerabilidades de red). Como consecuencia directa, los ingenieros de soporte se saturan atendiendo solicitudes de baja relevancia, provocando retrasos severos en la atención de eventos graves, el incumplimiento recurrente de los Acuerdos de Nivel de Servicio (SLA, por sus siglas en inglés) genera insatisfacción generalizada en los usuarios y pérdidas económicas o de productividad en la organización.

Antecedentes

Históricamente, las organizaciones han gestionado sus solicitudes de soporte técnico mediante plataformas rígidas basadas en formularios estáticos. En estos sistemas tradicionales, la categorización y la prioridad del problema dependen exclusivamente del criterio subjetivo del usuario o del filtro inicial de un operador humano, lo que genera un alto margen de error.

Con los avances recientes en la Inteligencia Artificial y la Ciencia de Datos, las áreas de TI en la industria han comenzado a adoptar modelos de aprendizaje automático (Machine Learning) y algoritmos de Procesamiento de Lenguaje Natural (PNL). Esta evolución tecnológica permite realizar una clasificación inicial automatizada mediante el análisis semántico directo de la descripción textual del incidente. La implementación de este enfoque ha demostrado reducir significativamente los errores humanos, optimizar los tiempos de primera respuesta y mejorar la asignación eficiente de recursos técnicos.

Justificación

La implementación de una solución tecnológica basada en datos se justifica por la necesidad de automatizar y objetivar el flujo de atención en la mesa de ayuda. Al analizar semánticamente la descripción textual del problema, el sistema permite predecir de forma autónoma la verdadera prioridad del incidente y derivarlo al departamento técnico correspondiente, eliminando la dependencia del sesgo del usuario y reduciendo drásticamente los tiempos de primera respuesta.

Objetivo general

Diseñar y desarrollar un prototipo de sistema inteligente capaz de procesar información, analizar datos estructurados y/o no estructurados, identificar patrones mediante técnicas de Machine Learning y procesar información textual mediante técnicas de PNL.

Objetivos específicos

El proyecto contemplará los siguientes objetivos específicos:

1. Identificar y analizar una problemática operativa simulado en la gestión de tickets de soporte técnico que pueda ser atendido mediante una solución basada en datos.
2. Obtener, organizar y preparar un conjunto representativo de 102,000 registros de soporte adecuados para el problema.
3. Diseñar la arquitectura técnica que represente el flujo completo de información desde su origen hasta la generación de resultados.
4. Implementar un modelo de Machine Learning supervisado que permita realizar una tarea de clasificación de la prioridad de los tickets.
5. Implementar técnicas de Procesamiento de Lenguaje Natural sobre información textual cuando la naturaleza del proyecto lo permita.
6. Aplicar técnicas de PNL para el análisis de sentimiento y el reconocimiento de entidades nombradas (NER) sobre los reportes textuales.
7. Desarrollar una interfaz, dashboard o mecanismo de consulta que permita visualizar e interpretar los resultados.
8. Integrar los diferentes componentes en un prototipo funcional.
9. Evaluar los resultados obtenidos y establecer las limitaciones, conclusiones y posibles mejoras de la solución.

Alcance

El prototipo abarcará el desarrollo completo de un pipeline en Python que procesará un dataset sintético de 100,000 registros de soporte técnico. El alcance incluye la etapa de limpieza y preparación de datos con Pandas, la implementación de modelos de PNL (extracción de entidades con NER y análisis de sentimiento) y de Machine Learning (entrenamiento de modelos de clasificación supervisada con scikit-learn), la creación de una estructura de bloques con hashing SHA-256 para la verificación de inmutabilidad, y el desarrollo de un Dashboard web interactivo para la visualización de resultados y demostración en vivo del sistema.

Funciones del sistema y resultados esperados

Al finalizar el desarrollo e implementación del sistema inteligente, se espera obtener los siguientes resultados y funciones operativas:

1. **Clasificación automatizada y precisa:** Obtener un modelo de Machine Learning capaz de analizar y predecir la prioridad real de los tickets (Baja, Media, Alta o Crítica) con una exactitud global (Accuracy) superior al 90%, minimizando la intervención humana en el primer filtro.
2. **Extracción inteligente de información:** Lograr que el motor de Procesamiento de Lenguaje Natural (PNL) identifique de manera automática los dispositivos afectados, los códigos de error y el nivel de frustración (sentimiento) directamente desde la redacción del usuario.
3. **Interfaz de usuario (Dashboard):** Contar con una plataforma visual e interactiva que permita a los administradores y técnicos de TI ingresar nuevos reportes para su evaluación en tiempo real, visualizar la carga de trabajo y verificar la integridad de los datos almacenados.
4. **Optimización operativa (Reducción de cuellos de botella):** Reducir teóricamente los tiempos de asignación y primera respuesta en la mesa de ayuda, mitigando el sesgo de urgencia provocado por los usuarios y permitiendo que los ingenieros se enfoquen en los incidentes verdaderamente críticos.

Limitaciones

El proyecto se basará en un conjunto de datos generado mediante simulación programada en Python debido a la falta un dataset optimo y adaptable a las necesidades de este proyecto.

Usuarios potenciales

Una vez analizado los principales problemas del análisis de tickets de soporte técnico, se han determinado los siguientes usuarios potenciales:

- **Ingenieros y técnicos de soporte de TI:** Para recibir tickets clasificados y priorizados automáticamente.
- **Coordinadores y administradores de mesa de ayuda:** Para supervisar métricas de rendimiento, carga de trabajo por departamento y volúmenes de incidencias mediante el dashboard.

ETAPA 2

DISEÑO DE LA SOLUCION INTELIGENTE

Funcionamiento y componentes del sistema

La solución propuesta consiste en un sistema inteligente e integrado que automatiza el ciclo de vida de un ticket de soporte técnico a través de un flujo distribuido en cinco etapas principales:

1. **Ingesta y preparación de datos:** El sistema recibe reportes de soporte estructurados y no estructurados (texto libre). Mediante rutinas vectorizadas con Pandas, se procesan y limpian los registros, eliminando duplicados, imputando valores faltantes y estandarizando los formatos de texto.
2. **Procesamiento de Lenguaje Natural (PNL):** La descripción del ticket es analizada para transformar el texto en vectores procesables. Mediante técnicas de PNL, se extrae el sentimiento del usuario (detectando niveles de frustración o urgencia) y se realiza el Reconocimiento de Entidades Nombradas (NER) para identificar automáticamente los dispositivos (servidores, laptops, routers) y códigos de error mencionados en el reporte.
3. **Análisis y predicción con Machine Learning:** Las características extraídas del texto y las variables del ticket son evaluadas por un modelo de clasificación supervisada (como Random Forest o SVM), el cual asigna automáticamente el nivel de prioridad del incidente (Baja, Media, Alta o Crítica) y sugiere el departamento responsable de atenderlo.
4. **Visualización en Dashboard:** A través de una interfaz gráfica interactiva, los usuarios pueden ingresar nuevos tickets para clasificarlos en tiempo real, consultar gráficas e indicadores estadísticos, y ejecutar el verificador criptográfico para comprobar la inmutabilidad de los tickets almacenados.

Adquisición y Preparación de Datos

Descripción de las variables

El conjunto de datos comprende 9 variables principales que abarcan información cualitativa, cuantitativa y texto no estructurado. La siguiente tabla detalla la estructura del dataset:

Variable	Tipo de Dato (Python / Pandas)	Descripción / Rol en el Proyecto	Ejemplo de Valor
id_ticket	object (cadena de texto)	Identificador único del reporte de soporte.	TCK-100045
fecha_creacion	datetime64[ns]	Timestamp con la fecha y hora de registro del ticket.	2026-03-15 14:22:10
area_solicitante	category (categórica)	Departamento de la empresa que reporta el fallo.	Ventas, Contabilidad
dispositivo_afectado	category (categórica)	Hardware, servicio o software específico involucrado.	Servidor Ubuntu 22.04
descripcion_problema	object (texto libre)	Redacción detallada (2-4 oraciones) para análisis de PNL.	"Se reporta que el nodo..."
departamento_asignado	category (categórica)	Área técnica de TI encargada de la atención.	Infraestructura Cloud
sentimiento	category (categórica)	Tono emocional detectado en la redacción.	Negativo, Neutral, Positivo
prioridad	category (ordinal)	**Variable objetivo (Target)** a predecir con ML.	Baja, Media, Alta, Crítica
tiempo_resolucion_horas	float64 (numérica continua)	Horas transcurridas hasta el cierre del ticket.	4.25

Fuente de información

Para el desarrollo de este proyecto integrador se utiliza una fuente de información de origen sintético, generada mediante simulación programada en Python empleando las librerías pandas, numpy y random.

Esta decisión corresponde requisitos generales del proyecto, debido principalmente por las necesidades específicas del proyecto que nos impedía datasets de registros reales de empresas. La simulación fue diseñada bajo un modelo probabilístico con reglas semánticas y correlaciones lógicas basadas en escenarios simulados de soporte técnico de TI.

Cantidad de registros

El dataset original sin procesar (tickets_soporte.csv) fue configurado con una base inicial de 100,000 registros de incidentes. Tras la inyección controlada de registros duplicados para simular fallas en los sistemas de captura, el dataset bruto alcanzó un volumen inicial total de 102,000 registros.

Durante la fase de diagnóstico preliminar, se identificaron 1,786 registros duplicados exactos y 1,017 registros con corrupción en la fecha. Al ejecutar la rutina de depuración secuencial en Pandas:

1. Primero se eliminaron los 1,786 registros duplicados mediante el método .drop_duplicates(), reduciendo el dataset a 100,214 observaciones (proceso en el cual se removieron 12 instancias duplicadas que contenían errores de fecha).
2. Posteriormente, se descartaron los 1,005 registros restantes con fechas corruptas no recuperables mediante .dropna().

Como resultado, el conjunto de datos final procesado (tickets_soporte_procesado.csv) quedó consolidado en exactamente 99,209 registros limpios y estructurados (102,000 - 1,786 - 1,005 = 99,209), garantizando un dataset libre de inconsistencias y listo para el entrenamiento de los modelos.

Tipos de datos

Como se puede observar en la tabla de variables, el proyecto maneja cuatro tipos de datos principales mediante Pandas:

- **Cadenas de texto (object):** Utilizadas para almacenar descripciones largas necesarias para el Procesamiento de Lenguaje Natural (PNL) y para los identificadores únicos.

- **Fechas (datetime64):** Para llevar el registro temporal preciso de cuándo se generó cada reporte.
- **Categóricas (category):** Se asignaron a variables como la prioridad, el departamento y el dispositivo, lo que ayuda a optimizar el consumo de memoria y facilita el entrenamiento del modelo predictivo.
- **Numéricas continuas (float64):** Usadas para calcular y operar estadísticamente los tiempos de resolución en horas.

Tratamiento de valores faltantes

El conjunto de datos inicial presentó un total de 4,078 registros nulos en dispositivo_afectado y 4,061 en tiempo_resolucion_horas (correspondientes a una tasa controlada del 4%), representando datos omisos durante el llenado manual de tickets.

Para su resolución se aplicaron las siguientes estrategias de imputación:

1. Variables Categóricas (dispositivo_afectado): Los 4,078 valores ausentes fueron imputados con la etiqueta explícita 'Sin Especificar'. Esta estrategia evita la pérdida de descripciones textuales valiosas y permite que los modelos de PNL sigan procesando el incidente.
2. Variables Numéricas (tiempo_resolucion_horas): Los 4,061 valores nulos fueron tratados mediante una imputación condicional por mediana agrupada según el nivel de prioridad del ticket (df.groupby('prioridad')). Esto garantiza que un ticket de prioridad Crítica reciba un valor de tiempo coherente con su categoría (por ejemplo, 2.2 horas) y no un promedio inflado por tickets de prioridad Baja (por ejemplo, 40 horas).

Tratamiento de valores atípicos

Para simular errores de captura o fallas de sincronización del sistema de tickets, se identificaron 514 valores atípicos extremos (0.5% del dataset) en la variable tiempo_resolucion_horas (inyectando valores imposibles como tiempos negativos de -15.0 horas).

El tratamiento se ejecutó mediante filtrado de límites operativos racionales:

- Identificación: Se establecieron como valores irreales todas las observaciones donde tiempo_resolucion_horas < 0 (tiempos negativos) o tiempo_resolucion_horas > 120 horas (resoluciones superiores a 5 días continuos sin justificación).
- Aislamiento e Imputación: Estos 514 valores irreales fueron reasignados inicialmente como NaN para posteriormente ser imputados mediante la mediana del grupo de prioridad correspondiente, restableciendo la distribución lógica de la variable sin sesgar los modelos predictivos.

Transformaciones realizadas

El proceso de limpieza del dataset se realizó mediante código en Python utilizando las funciones de Pandas:

1. Eliminación de duplicados exactos: Se identificaron y eliminaron 1,786 registros repetidos mediante el método .drop_duplicates().
2. Estandarización de textos: Al detectar inconsistencias de formato en los nombres de departamentos (como espacios en blanco extra o letras mayúsculas revueltas), se aplicaron transformaciones de cadena para limpiar los bordes y normalizar a minúsculas, reestructurándolos mediante un diccionario de mapeo hacia los nombres oficiales.
3. Conversión y filtrado de fechas corruptas: Se identificaron 1,017 registros con la cadena "ERROR_REGISTRO_SISTEMA". Al forzar la conversión de la columna al tipo datetime, dichos textos se convirtieron en valores NaT (vacíos temporales) y fueron descartados definitivamente del dataset al ser irrecuperables.

Justificación del enfoque de IA y técnicas de PNL seleccionadas

Para la solución de este problema, se tomó la decisión técnica de entrenar modelos propios desde cero en lugar de utilizar modelos preentrenados comerciales (como ChatGPT o modelos de lenguaje masivos - LLMs) por tres razones fundamentales:

- **Privacidad:** Garantizar el control total sobre los datos sensibles de soporte técnico de la empresa.
- **Optimización de recursos:** El modelo desarrollado puede ejecutarse localmente sin depender de conexiones a internet, consumo excesivo de memoria o pagos por uso de APIs de terceros.
- **Especialización:** Permite crear un modelo especializado de forma exclusiva en el vocabulario técnico y los procesos específicos de nuestra mesa de ayuda.

Selección de técnicas para el Procesamiento de Texto (PNL): Para transformar el texto libre de los reportes en datos analizables, se seleccionó la técnica de representación vectorial TF-IDF (Frecuencia de Término - Frecuencia Inversa de Documento) por encima de otras alternativas más complejas como Word2Vec o Embeddings de redes neuronales profundas. La justificación de esta elección es que TF-IDF es estadísticamente ideal para extraer términos técnicos críticos (ej. "servidor", "caída", "latencia", "base de datos"). Esta técnica le otorga un peso matemático mayor a las palabras raras pero importantes para diagnosticar un fallo, ignorando palabras de relleno de forma muy eficiente.

Selección del modelo predictivo (Machine Learning): Como algoritmo de clasificación final, se seleccionó Random Forest. La justificación de esta decisión radica en su excelente sinergia con la técnica TF-IDF. Random Forest maneja de manera muy eficiente las matrices dispersas (generadas por el texto) combinadas con variables categóricas (como el departamento o el tipo de hardware). Al estar compuesto por múltiples árboles de decisión, es un algoritmo altamente resistente al "sobreajuste" (overfitting) y, a diferencia de una red neuronal convencional, funciona como un modelo transparente (caja blanca) que nos permite rastrear qué características tuvieron mayor peso al decidir si un ticket era de prioridad baja o crítica.

Modelo de Machine Learning

Definición del problema

El problema se dirige en la necesidad de automatizar la categorización de incidentes en una mesa de ayuda de TI. Al depender del criterio subjetivo de los usuarios, se generan cuellos de botella por clasificaciones erróneas. Computacionalmente, esto se define como un problema de clasificación multiclase, donde nuestro objetivo es mapear una serie de características (extraídos de texto libre y datos del ticket que llega a TI) hacia una clase discreta que represente el nivel de urgencia real.

Tipo de aprendizaje

Se implementó un enfoque de Aprendizaje Automático Supervisado. La naturaleza del dataset histórico proporciona ejemplos previamente etiquetados donde cada incidente (matriz X) cuenta con una resolución de prioridad conocida (vector Y). A través de un aprendizaje por inferencia deductiva, el sistema minimiza el error empírico de predicción sobre clases discretas, lo cual también optimizara los tiempos de ayuda y resolución de los tickets.

Algoritmo seleccionado

Se seleccionó un modelo de Random Forest. La elección técnica de este algoritmo de aprendizaje por ensamblado (Ensemble Learning) obedece a su alta tolerancia al ruido, su robustez frente al sobreajuste (overfitting) en datos de alta dimensionalidad como lo es nuestro dataset sintético original, y su capacidad nativa para capturar relaciones no lineales complejas entre matrices dispersas (como las generadas por el análisis de texto) y variables predictoras estrictamente categóricas.

Características utilizadas

El pipeline de preprocesamiento consumió variables de distinta naturaleza algorítmica. Se utilizaron las variables categóricas area_solicitante, dispositivo_afectado, departamento_asignado y sentimiento, las cuales fueron transformadas mediante una codificación matricial de variables ficticias (One-Hot Encoding). Simultáneamente, la característica de texto libre descripcion_problema se vectorizó utilizando la frecuencia de término frecuencia inversa de documento (TF-IDF), extrayendo características semánticas mediante n-gramas estandarizados.

Variable objetivo

La variable objetivo o Target (clase a predecir) corresponde a la característica prioridad. Esta variable de naturaleza categórica ordinal se divide en cuatro intervalos discretos: Baja, Media, Alta y Crítica.

Preparación de datos

Tras la fase de limpieza exhaustiva documentada previamente, el dataset consolidado de 99,209 registros fue sometido a una técnica de validación por retención de datos (Hold-Out Cross Validation). Para prevenir la fuga de datos (data leakage), el conjunto se dividió secuencialmente en un 70% para la etapa de entrenamiento (69,446 registros), un 15% como conjunto de evaluación para el diagnóstico de hiperparámetros (14,881 registros) y un 15% final bajo aislamiento estricto para las pruebas empíricas (14,882 registros).

Fuentes de información

- **Dataset Sintético Interno de Soporte Técnico:** Archivos tickets_soporte.csv (102,000 registros iniciales generados mediante simulación estocástica en Python) y tickets_soporte_procesado.csv (99,209 registros depurados y normalizados tras el tratamiento de nulos, duplicados y outliers).
- **Documentación Oficial del Lenguaje Python (v3.x):** Especificación del entorno de programación utilizado para el desarrollo integral del script de simulación y el pipeline de datos.
- **Documentación de la Biblioteca Pandas:** Especificaciones de métodos de estructuración tabular, vectorización, imputación por medianas agrupadas (groupby), conversión de formatos temporales (to_datetime) y descarte de duplicados (drop_duplicates)
- **Documentación de la Biblioteca NumPy:** Funciones para el cálculo numérico multivariado y generación de arreglos matriciales en la simulación probabilística.
- **Documentación de Scikit-Learn:** Guías de implementación del modelo clasificador supervisado Random Forest, vectorización de texto con TF-IDF, codificación de variables categóricas (One-Hot Encoding) y partición de datos por validación cruzada tipo retención (Hold-Out).
- **Manuales de Buenas Prácticas de Mesa de Ayuda (ITIL / Gestión de Incidentes de TI):** Criterios operacionales aplicados para la estandarización de prioridades (Baja, Media, Alta, Crítica) y el cálculo de cumplimiento de Acuerdos de Nivel de Servicio (SLA).
- **Estándar Criptográfico FIPS PUB 180-4:** Especificación de la función hash segura SHA-256 empleada para el mecanismo de auditoría e inmutabilidad de la estructura de bloques de tickets.

Fuentes bibliográficas

- Axelos. (2019). ITIL Foundation: ITIL 4 Edition. TSO (The Stationery Office).
- Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324
- Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., … Oliphant, T. E. (2020). Array programming with NumPy. Nature, 585(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2
- Jurafsky, D., & Martin, J. H. (2023). Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition (3.ª ed. borrador). Stanford University. https://web.stanford.edu/~jurafsky/slp3/
- McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt & J. Millman (Eds.), Proceedings of the 9th Python in Science Conference (pp. 56–61). https://doi.org/10.25080/Majora-92bf1924-00a
- National Institute of Standards and Technology. (2015). Secure Hash Standard (SHS) (Federal Information Processing Standards Publication FIPS PUB 180-4). U.S. Department of Commerce. https://doi.org/10.6028/NIST.FIPS.180-4
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.
- Russell, S., & Norvig, P. (2020). Artificial intelligence: A modern approach (4.ª ed.). Pearson.
- Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information Processing & Management, 24(5), 513–523. https://doi.org/10.1016/0306-4573(88)90021-0
- Van Rossum, G., & Drake, F. L. (2009). Python 3 Reference Manual. CreateSpace.